

Università degli Studi di Padova

DIPARTIMENTO DI MATEMATICA "TULLIO LEVI-CIVITA"

CORSO DI LAUREA IN INFORMATICA



**SmartFarm Technologies: Sistema Integrato
per l'ottimizzazione e l'efficientamento della
gestione agricola sostenibile**

Tesi di laurea

Relatore

Prof. Marco Zanella

Laureando

Valerio Occhinegro

Matricola 2011069

Valerio Occhinegro: *SmartFarm Technologies: Sistema Integrato per l'ottimizzazione e l'efficientamento della gestione agricola sostenibile*, Tesi di laurea, © Dicembre 2024.

Sommario

Il presente documento descrive il lavoro svolto durante il periodo di stage dal laureando Valerio Occhinegro presso l'azienda Spazio Dev Srl di Tombolo (PD). Lo stage, svoltosi al termine del percorso di studi della Laurea Triennale in "Scienze Informatiche", ha avuto una durata complessiva di 306 ore.

Il lavoro in questione è stato suddiviso in 4 diverse fasi, ognuna delle quali caratterizzata da obiettivi specifici e scadenze precise, e si basa su un'analisi intelligente di siti web, improntata alla vendita dei servizi aziendali a potenziali clienti. Il ruolo del laureando è quello di gestire e archiviare i siti web target e successivamente classificarli per fornire a Spazio Dev input utili per acquisire l'abilità di ampliare la quantità dei propri clienti in maniera rapida e automatizzata. Nello specifico, il progetto di stage ha l'obiettivo di sviluppare competenze avanzate nell'intelligenza artificiale, con un focus particolare sulla classificazione e organizzazione dei dati; uno studio che si inserisce nel contesto di "SalesCRM: Customer Relationship Manager ", un sistema integrato che mira a ottimizzare la gestione delle relazioni con i clienti e a migliorare l'efficienza dei vendoritori. INSERIRE VERO TITOLO Lo scopo ultimo del progetto è la creazione di un sistema intelligente che sia in grado di analizzare dataset complessi, classificare la qualità dei siti web (siti che potrebbero essere migliorati e siti che non necessitano di modifiche) e proporre i propri servizi alle aziende che ne necessitano in maniera automatica. Il laureando è responsabile dello sviluppo di funzionalità chiave del sistema che consentiranno di fornire soluzioni strategiche agli utilizzatori della piattaforma.

“Non importa quanto piano vai, finché non ti fermi”

— Confucio

Ringraziamenti

Padova, Dicembre 2024

Valerio Occhinegro

Indice

1	Introduzione	1
1.1	L’azienda	1
1.2	Servizi offerti	2
1.3	Clientela	2
1.4	Prodotto di punta	3
1.5	Organizzazione del testo	3
2	Processi e metodologie	4
2.1	Ciclo di vita del software	4
2.1.1	Filosofia Agile	4
2.1.2	Tecnologie di supporto	5
2.2	Gestione della configurazione	5
2.2.1	Tecnologie di supporto	6
3	Il progetto	8
3.1	Analisi del progetto	8
3.1.1	SalesCRM	8
3.1.2	Integrazione	10
3.2	Analisi e gestione dei rischi	10
3.3	Obiettivi	11
4	Analisi dei requisiti	12
4.1	Casi d’uso	12
5	Strumenti e tecnologie	16
5.1	Strumenti	16
5.1.1	Visual Studio Code	16
5.1.2	PhpMyAdmin	17
5.1.3	remoteripple	17
5.2	Tecnologie	18
5.2.1	Python	18
5.2.2	CUDA	19
5.2.3	Docker	20
5.2.4	DDEV	20
5.2.5	WSL	21
5.2.6	Laravel	21
5.2.7	Filament	22
5.2.8	MySQL	23

6 Basi teoriche	24
6.1 Immagini raster	24
6.2 Features	24
6.3 Autoencoder	24
6.4 PCA	24
6.5 K-means	24
6.6 Transfer learning	24
6.7 Loss functions	24
6.8 pesi	24
6.9 activation function	24
6.10 fine-tuning	24
6.11 epoches	24
6.12 learning rate	24
7 Progettazione e codifica	25
7.1 Architettura	25
7.2 Cattura immagini	26
7.3 Clustering	27
7.3.1 Preparazione delle immagini	27
7.3.2 Estrazione delle features	28
7.3.3 Applicazione del clustering	29
7.4 Valutazione	30
7.4.1 Preparazione del dataset	30
7.4.2 Addestramento del modello	30
7.4.3 Fine-tuning del modello	30
7.4.4 Valutazione delle immagini	30
7.5 Invio e-mail	31
7.6 Database	31
7.6.1 Domains	31
7.6.2 Pages	31
8 Conclusioni	33
8.1 Consuntivo finale	33
8.2 Raggiungimento degli obiettivi	33
8.3 Conoscenze acquisite	33
8.4 Valutazione personale	33
A Appendice A	34
Acronimi e abbreviazioni	35
Glossario	36
Bibliografia	37

Elenco delle figure

1.1	Logo dell'azienda	2
1.2	Logo dell'applicazione RelAI	3
2.1	Schema del modello scrum	4
2.2	Logo di Plane	5
2.3	Logo di Telegram	5
2.4	Logo di Git	6
2.5	Logo di Gitea	6
2.6	Esempio di Git Flow	7
3.1	Home page di SalesCRM	9
3.2	Calendario contenuto all'interno di SalesCRM	9
3.3	Mappa contenuta all'interno di SalesCRM	9
4.1	Use Case - UC0: Scenario principale	12
4.2	Use Case - UC1: Scenario principale	13
4.3	Use Case - UC2: Clusterizzazione degli screenshot	14
4.4	Use Case - UC3: IA classificativa	14
4.5	Use Case - UC4: invio e-mail	15
5.1	Logo di Visual Studio Code	16
5.2	Logo di phpMyAdmin	17
5.3	Logo di Remote Ripple	17
5.4	Python e librerie utilizzate	19
5.5	Logo di CUDA	20
5.6	Logo di Docker	20
5.7	Logo di DDEV	21
5.8	Logo di WSL	21
5.9	Logo di Laravel	22
5.10	Esempio di interfaccia grafica creata in Filament	22
5.11	Logo di Filament	22
5.12	Logo di MySQL	23
7.1	Schema architetturale del progetto	26
7.2	Schema della fase di cattura	27
7.3	Conversione e ridimensionamento	28
7.4	Struttura del tensore	28
7.5	Esempio di featuremaps	29
7.6	Struttura di ResNet50	29

7.7	Clustering effettuato utilizzando 20 clusters e 3000 immagini	30
7.8	Struttura del dataset	31
7.9	Schema della tabella Domains	32
7.10	Schema della tabella Pages	32

Elenco delle tabelle

3.1	Tabella degli obiettivi	11
-----	-----------------------------------	----

Capitolo 1

Introduzione

L'esperienza dello stage è l'elemento che porta alla conclusione del percorso accademico dello studente; pertanto è da considerare una delle prove più formanti e impegnative di tutto l'arco di studi.

Durante questo periodo lo studente ha l'occasione di mettere alla prova le conoscenze acquisite negli anni, ma soprattutto ha la possibilità di valutare le proprie abilità di autoapprendimento, scontrandosi con tecnologie e problemi mai visti in precedenza. L'introduzione al mondo del lavoro è fondamentale per rendere il più lineare possibile la transizione da studio ad applicazione pratica delle conoscenze, fornisce inoltre un assaggio delle responsabilità che gravano su un programmatore durante la permanenza nella propria azienda. In questo capitolo viene presentata l'azienda Spazio Dev presso la quale lo studente ha svolto lo stage nel periodo che va dal giorno 23/09/2024 al 14/11/2024.

1.1 L'azienda

Spazio Dev è una software house italiana nata a Tombolo (PD) nel 2023; nonostante la giovane età è riuscita ad affermarsi nel suo campo dando vita a molteplici progetti ambiziosi. L'obiettivo primario dell'azienda è quello di supportare diverse imprese tramite soluzioni digitali e tecnologiche sviluppate in base alle necessità. L'azienda conta 16 membri che ricoprono i diversi ruoli di sviluppatori, grafici, responsabili marketing e sistemisti. L'organico ha un'età media inferiore ai trenta anni, questo fattore contribuisce a rendere l'ambiente lavorativo dinamico e conviviale, perfetto per coltivare nuovi talenti. Spazio Dev affianca e aggiorna il cliente tramite una comunicazione costante, necessaria per adattare il prodotto alle esigenze richieste. Il focus principale dell'azienda è infatti quello di fornire prodotti specifici per ciascun cliente e non la vendita di prodotti standard.

Il logo dell'azienda è rappresentato in Fig. 1.1



Figura 1.1: Logo dell'azienda

1.2 Servizi offerti

L'offerta di Spazio Dev è molto ampia e consente allo staff di aiutare i clienti nei seguenti ambiti:

- **Sviluppo di siti web:** La produzione di siti web è uno dei servizi più richiesti all'azienda e ne rappresenta uno dei motori trainanti. Gli sviluppatori hanno un occhio di riguardo per le nuove tecnologie, che sfruttano per offrire al cliente un prodotto accattivante e ottimizzato in maniera tale da garantire numerose visite.
- **Sviluppo software e integrazione IA:** I software prodotti sono solitamente indirizzati a una clientela variegata e possono spaziare in vari campi, in base alle esigenze di ciascun acquirente. Gli applicativi più venduti hanno come scopo principale la gestione dell'azienda e delle relazioni con i clienti. Per differenziarsi dalla concorrenza Spazio Dev ha introdotto nuove funzionalità impiegando modelli di IA capaci di predire trend futuri di acquisto e di anticipare i bisogni dei clienti.
- **Marketing:** Gli esperti di marketing creano contenuti di alta qualità, pertinenti e ottimizzati, atti a migliorare la presenza on-line del brand. Per aumentare l'engagement vengono studiate apposite campagne social e di posta elettronica.

1.3 Clientela

La clientela di Spazio Dev è molto variegata ed è suddivisibile nelle seguenti categorie:

- imprese di varie dimensioni specializzate in commercio e manifattura che necessitano di migliorare la propria presenza nel web, la gestione della contabilità, la logistica e le risorse umane.
- start-up in cerca di visibilità e di strategie di marketing.
- liberi professionisti come avvocati, medici, eccetera.

1.4 Prodotto di punta

RelAI (Fig. 1.2) rappresenta in tutto e per tutto l’azienda poiché nasce dall’unione di tutti i suoi core business: sviluppo web, integrazione IA e marketing. Il software è un CRM (Customer Relationship Manager) in cloud che consente di personalizzare le relazioni con i clienti e di incrementare le vendite grazie a campagne di comunicazione su misura. La sua architettura modulare e le numerose configurazioni si adattano perfettamente in molti settori. L’IA implementata è utile per predire futuri trend di acquisto fondamentali per la creazione di strategie di marketing efficaci.



Figura 1.2: Logo dell’applicazione RelAI

1.5 Organizzazione del testo

Il secondo capitolo descrive ...

Il terzo capitolo approfondisce ...

Il quarto capitolo approfondisce ...

Il quinto capitolo approfondisce ...

Il sesto capitolo approfondisce ...

Il settimo capitolo approfondisce ...

Nell’ottavo capitolo si tratta ...

Per quanto riguarda la stesura del documento sono state adottate le seguenti convenzioni tipografiche:

- gli acronimi, le abbreviazioni e i termini ambigui o di uso non comune menzionati vengono definiti nel glossario, situato alla fine del presente documento;
- per la prima occorrenza dei termini riportati nel glossario viene utilizzata la seguente nomenclatura: *parola^[g]*;
- i termini in lingua straniera o facenti parti del gergo tecnico sono evidenziati con il carattere *corsivo*.

Capitolo 2

Processi e metodologie

In questo capitolo sono riassunti i processi e le metodologie che lo studente ha applicato durante lo sviluppo del progetto di stage.

2.1 Ciclo di vita del software

Il ciclo di vita del software è l'insieme delle attività e dei processi che tutti i membri coinvolti devono seguire per la buona riuscita del prodotto. L'adozione di un modello di ciclo di vita è fondamentale per rispettare le scadenze, rimanere all'interno del budget ed evitare conflitti all'interno e all'esterno del team.

2.1.1 Filosofia Agile

Per favorire la collaborazione l'azienda si affida alla filosofia Agile e in particolare al modello scrum (Fig. 2.1) che ha come unità fondamentale lo "sprint" ossia un periodo di tempo breve (1 settimana) che viene utilizzato per sviluppare e testare nuove funzionalità; grazie a questi avanzamenti rapidi è possibile fornire codice flessibile e rapidamente adattabile alle nuove esigenze.

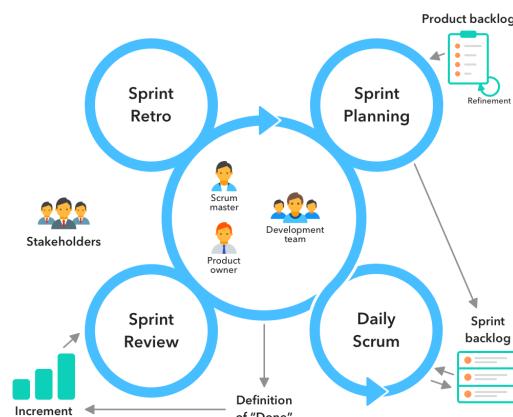


Figura 2.1: Schema del modello scrum

2.1.2 Tecnologie di supporto

- Plane (Fig. 2.2): è un ITS (Issue Tracking System) utilizzato per monitorare l'avanzamento del progetto e per assegnare a ciascun membro i compiti da effettuare; consente a tutte le parti coinvolte di avere una visione di insieme su quello che bisogna realizzare per portare a compimento lo sviluppo. In particolare è stato scelto perché altamente personalizzabile e per la sua natura open-source.



Figura 2.2: Logo di Plane

- Telegram (Fig. 2.3): è una piattaforma di messaggistica completa con molte funzionalità, viene sfruttata dall'azienda per coordinare i vari team di lavoro tramite l'ausilio di chat di gruppo. Fornisce inoltre molte funzionalità avanzate come bot utili per i più svariati casi d'uso.



Figura 2.3: Logo di Telegram

2.2 Gestione della configurazione

La gestione della configurazione è il processo tramite il quale è possibile identificare, controllare e coordinare i vari componenti del software e le risorse a esso associate durante l'intero ciclo di vita del prodotto. Grazie a questo processo gli sviluppatori possono tenere traccia delle modifiche e gestire le varie versioni garantendo il funzionamento del prodotto nel tempo.

2.2.1 Tecnologie di supporto

Le tecnologie utilizzate per il versionamento del prodotto sono:

- Git (Fig. 2.4): è un DVCS (Distributed Version Control System) ampiamente diffuso che consente di gestire e monitorare i cambiamenti del codice e della documentazione. Questo strumento è fondamentale per avere una storia completa dello sviluppo da poter sfruttare in caso di necessità. Il codice viene inserito all'interno di un repository, ossia una cartella che contiene tutti i file relativi al progetto, dove è possibile salvare ogni cambiamento tramite commit. Il commit segnala ogni modifica e la data in cui viene attuata, è dunque sufficiente spostarsi tra i vari commit per tornare ad una versione più o meno aggiornata.



Figura 2.4: Logo di Git

- Gitea (Fig. 2.5): è un servizio che supporta le repository di Git, è simile a GitHub, Bitbucket e GitLab, ma ha il vantaggio di essere self-hosted. Essendo tutti i repository aziendali mantenuti sul server interno, le comunicazioni atte al versionamento hanno risposta molto rapida.



Figura 2.5: Logo di Gitea

Regole di branch e commit

Per standardizzare l'utilizzo delle tecnologie di versionamento l'azienda adotta due convenzioni:

- Git Flow (Fig. 2.6): è un modello di branching ideato per avere un miglior controllo delle release.
- Conventional Commits: è una specifica basata su regole, che consentono una facile lettura dei commit sia da parte di utenti che da parte di strumenti automatici.



Figura 2.6: Esempio di Git Flow

Capitolo 3

Il progetto

Questo capitolo contiene le informazioni preliminari che sono state fornite allo studente e le misure preventive adottate per iniziare la produzione.

3.1 Analisi del progetto

Il progetto si basa sull'integrazione di un nuovo workflow all'interno di un applicativo preesistente; lo studente deve occuparsi dello sviluppo di una soluzione in grado di migliorare la portata dell'azienda per quanto riguarda il raggiungimento di nuovi clienti.

3.1.1 SalesCRM

SalesCRM è il CRM che viene utilizzato dai commerciali interni all'azienda; contiene tutte le informazioni relative ai contatti che sono stati raggiunti dal reparto vendite. Gli utenti sono in grado di immagazzinare i dati raccolti su clienti e potenziali clienti tramite un interfaccia intuitiva sviluppata utilizzando [Laravel](#) e [Filament](#).

Componenti principali

- Home page (Fig. 3.1) contenente grafici informativi.
- Il modulo contenente il calendario (Fig. 3.2) è utile per pianificare appuntamenti e visite.
- La sezione della mappa (Fig. 3.3) viene sfruttato per conoscere il posizionamento dei clienti e organizzare incontri locali.

3.1. ANALISI DEL PROGETTO

9



Figura 3.1: Home page di SalesCRM



Figura 3.2: Calendario contenuto all'interno di SalesCRM

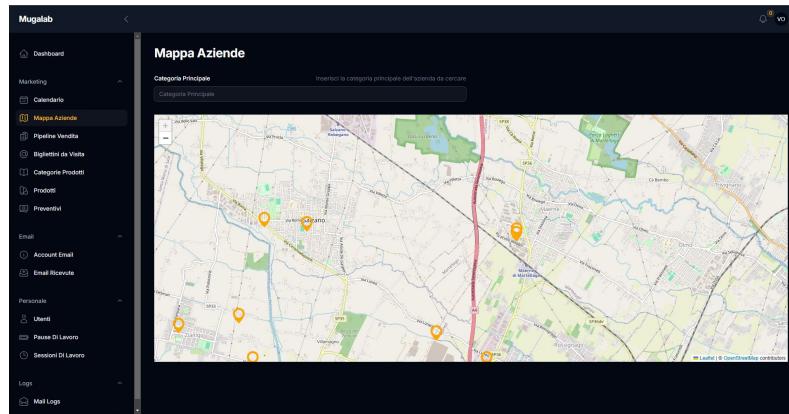


Figura 3.3: Mappa contenuta all'interno di SalesCRM

3.1.2 Integrazione

- Raccolta di dati: l'applicativo ha una funzionalità di web-scraping che raccoglie i link dei siti web di tutti i potenziali clienti, il compito del tirocinante è quello di creare un workflow automatico che si integri con il web-scraper per acquisire screenshot delle varie pagine del sito web.
- Clusterizzazione: la fase successiva alla raccolta dei dati consiste nello sviluppo di una IA addestrata in maniera non supervisionata che sia in grado di suddividere le varie immagini in clusters, differenziati in base alle caratteristiche riconosciute in ogni sito.
- IA classificativa: in seguito alla raccolta di un dataset di dimensioni congrue si procede alla suddivisione manuale degli screenshot precedentemente clusterizzati su una base qualitativa (siti migliorabili e siti ottimi); questo processo viene svolto con l'ottica dell'addestramento di una IA classificativa. L'IA addestrata in maniera supervisionata ha l'obiettivo di affidare un punteggio in valori centesimali a ogni sito.
- Invio di e-mail automatizzato: l'automazione della posta elettronica procede con l'invio di e-mail personalizzate ai proprietari dei siti web che hanno ricevuto una valutazione scarsa, per offrire loro un servizio di miglioramento.

3.2 Analisi e gestione dei rischi

Durante l'analisi del progetto lo stagista ha individuato alcuni rischi in cui potrà incorrere. Nella lista seguente sono elencati i rischi e le soluzioni ideate.

1. Rimodulazione dell'attività

Descrizione: dopo un mese dall'inizio dello stage lo studente è stato riposizionato sul progetto attuale scartando il progetto precedente e trovandosi dunque con meno settimane a disposizione per la produzione.

Soluzione: ridimensionamento delle attività e richieste di supporto più frequenti.

2. Approccio sperimentale

Descrizione: il progetto prevede dei contributi originali e sperimentali per cui non sono disponibili soluzioni già pronte.

Soluzione: auto apprendimento tramite tutorial on-line e richiesta di coinvolgimento di colleghi più esperti nell'ambito.

3. Costo dell'Addestramento

Descrizione: l'addestramento dell'intelligenza artificiale richiede l'utilizzo di potenti GPU di cui spesso l'hardware a disposizione è sprovvisto.

Soluzione: utilizzo del server aziendale per l'addestramento su CPU, ottenendo un compromesso tra costi e tempo di addestramento.

4. Quantità di dati di training insufficiente

Descrizione: l'IA necessita una grande quantità di dati in input per effettuare un training efficace.

Soluzione: aumento manuale del dataset e ricerca di dataset già pronti on-line.

5. Risultati della clusterizzazione non soddisfacenti

Descrizione: il clustering potrebbe risultare non conforme alle aspettative.

Soluzione: valutare la quantità di cluster da creare e sperimentare con altri metodi di clustering.

6. Overfitting del modello

Descrizione: il modello IA fornisce valutazioni accurate solo per le immagini utilizzate durante il training.

Soluzione: sperimentare con metodi per la risoluzione dell'overfit (dropout, cross-validation, ecc...).

7. Dipendenze delle librerie

Descrizione: il progetto utilizza molte tecnologie e librerie differenti, è probabile che si presentino delle incompatibilità.

Soluzione: utilizzo del minor numero possibile di librerie e verifica delle compatibilità prima dell'inizio della scrittura del codice.

3.3 Obiettivi

Gli obiettivi hanno lo scopo di delineare il percorso che lo studente deve affrontare per portare a termine il progetto nella maniera desiderata dall'azienda. Sono suddivisibili in:

- **O:** obbligatori
- **D:** desiderabili
- **F:** facoltativi

Codice	Descrizione
O01	Implementare un sistema robusto per la cattura degli screenshot, assicurando l'integrazione con il database per l'archiviazione e l'analisi.
O02	Garantire la creazione di una documentazione tecnica completa che supporti sia l'uso che la manutenzione del sistema sviluppato.
O03	Creazione di un IA in grado di suddividere in cluster i siti web.
O04	Creazione di un IA classificativa in grado di assegnare un punteggio ai siti-web analizzati.
D01	Aggiungere la valutazione creata dall'IA nel database utilizzato dal CRM.
D02	Automatizzare l'invio di e-mail alle aziende che hanno ottenuto una valutazione scarsa.
F01	Migliorare la raccolta dei dati delle aziende dal web
F02	Aggiornare automaticamente la valutazione dei siti web

Tabella 3.1: Tabella degli obiettivi

Capitolo 4

Analisi dei requisiti

L'analisi dei requisiti è alla base della comprensione del prodotto da sviluppare, è utile per chiarire eventuali dubbi e per procedere in maniera spedita evitando perdite di tempo future

4.1 Casi d'uso

Per rendere più chiari i casi d'uso sono stati utilizzati dei diagrammi di tipo [Unified Modeling Language \(UML\)](#). Questo tipo di diagrammi descrivono funzioni e servizi forniti dal sistema agli attori che lo utilizzano. Essendo il progetto l'implementazione di un workflow automatico, le interazioni dell'utente devono essere minime. Per questo i casi d'uso sono pochi e molto sintetici.

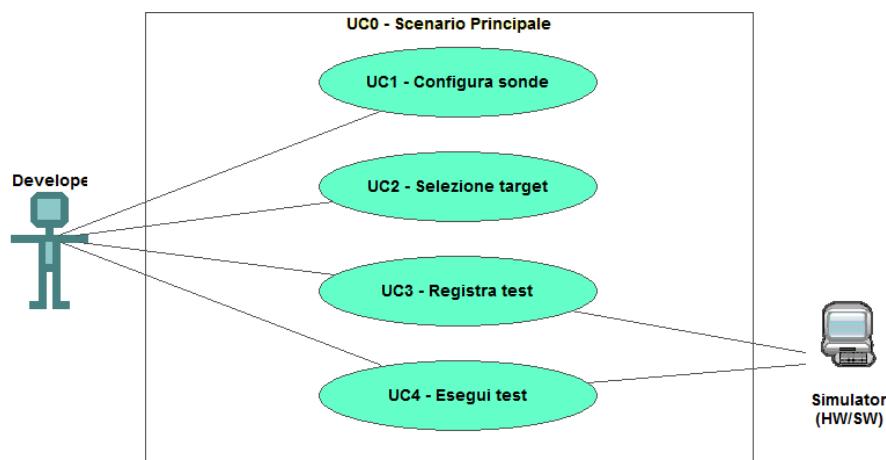


Figura 4.1: Use Case - UC0: Scenario principale

UC0: Scenario principale

Attori Principali: Programmatore.

Precondizioni: Il programmatore ha avviato l'ambiente di programmazione integrato.

Descrizione: Avvio delle componenti base dell'applicativo.

Postcondizioni: Il sistema è pronto per eseguire il workflow.



Figura 4.2: Use Case - UC1: Scenario principale

UC1: Acquisizione screenshot

Attori Principali: Programmatore, Web-scraper.

Precondizioni: Il web-scraper ha già raccolto i link alle pagine dei siti web delle aziende.

Descrizione: Il programmatore prepara il workflow per acquisire in maniera automatica gli screenshot delle pagine raccolte in precedenza.

Postcondizioni: Gli screenshot vengono salvati nel database, pronti per la fase di analisi e classificazione.




Figura 4.3: Use Case - UC2: Clusterizzazione degli screenshot

UC2: Clusterizzazione degli screenshot

Attori Principali: Programmatore, IA non supervisionata.

Precondizioni: Gli screenshot delle pagine sono stati acquisiti e salvati nel database.

Descrizione: Il programmatore avvia il processo di clustering, che organizza gli screenshot in clusters in base alle feature estratte.

Postcondizioni: Gli screenshot vengono clusterizzati e inseriti in apposite cartelle.

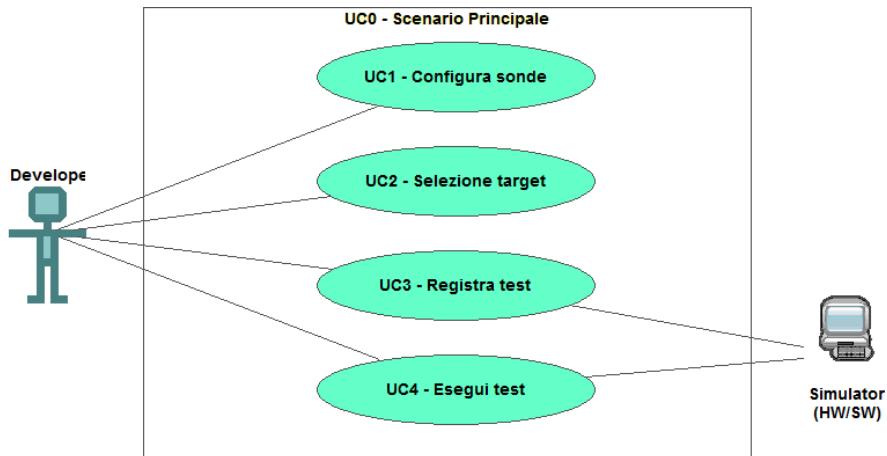


Figura 4.4: Use Case - UC3: IA classificativa

UC3: Valutazione qualitativa e classificazione

Attori Principali: Programmatore, IA classificativa.

Precondizioni: Gli screenshot sono stati inseriti in cartelle.

Descrizione: Lo sviluppatore addestra l'IA classificativa sfruttando i cluster precedentemente creati, e creando un dataset.

Postcondizioni: Ogni sito ottiene un punteggio qualitativo che viene salvato nel database per operazioni future.

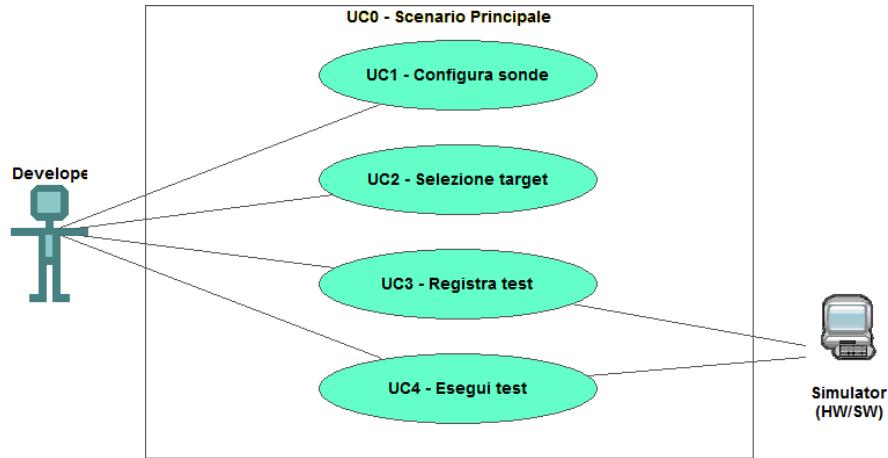


Figura 4.5: Use Case - UC4: invio e-mail

UC4: Automazione dell'invio di e-mail

Attori Principali: Programmatore, Sistema di posta elettronica.

Precondizioni: I siti web contenuti nel database hanno ricevuto una valutazione.

Descrizione: Il sistema invia automaticamente e-mail personalizzate ai proprietari dei siti con punteggi di qualità bassi, offrendo servizi di miglioramento.

Postcondizioni: Le e-mail vengono inviate con successo ai destinatari.

Capitolo 5

Strumenti e tecnologie

L'obiettivo principale di questo capitolo è l'illustrazione delle tecnologie degli strumenti ausiliari utilizzati per raggiungere lo scopo finale del progetto

5.1 Strumenti

Gli strumenti di supporto adoperati per il progetto sono elencati nella lista seguente.

5.1.1 Visual Studio Code

Visual Studio Code (Fig. 5.1): è un ambiente di sviluppo integrato, disponibile per Linux, macOS e Windows. È un'applicazione che supporta la maggior parte dei linguaggi di programmazione ed è quindi molto vantaggiosa per lavorare ad un progetto multi-linguaggio senza dover cambiare ambiente. Un'altra delle funzionalità principali è la fornitura di numerose estensioni che semplificano il processo di scrittura e verifica del codice.

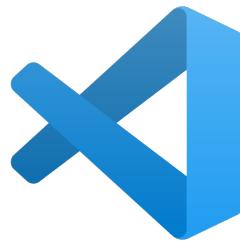


Figura 5.1: Logo di Visual Studio Code

5.1.2 PhpMyAdmin

PhpMyAdmin (Fig. 5.2): è una web-app scritta utilizzando il linguaggio di programmazione PHP, che offre la capacità di gestione di un database MySQL attraverso un browser qualsiasi. Consente la creazione di tabelle, l'inserimento, la modifica e l'interrogazione dei dati. Fornisce un'interfaccia grafica per la visione d'insieme e per le operazioni amministrative.



Figura 5.2: Logo di phpMyAdmin

5.1.3 remoteripple

Remote Ripple (Fig. 5.3): è un software per l'accesso remoto, che viene utilizzato dallo studente per avviare i programmi presenti nel server aziendale.



Figura 5.3: Logo di Remote Ripple

5.2 Tecnologie

Nelle sezioni seguenti viene data una spiegazione di tutte le tecnologie utilizzate.

5.2.1 Python

Versione: 3.9.0

Python (Fig. 5.4) è un linguaggio di programmazione ampiamente utilizzato in settori come il data mining e l'intelligenza artificiale. Offre solide basi per l'integrazione con disparati linguaggi, ma il vantaggio più di risalto è la presenza di numerose librerie che aiutano lo sviluppatore a velocizzare il processo di codifica; in particolare sono state utilizzate le seguenti librerie:

Tensorflow-gpu 2.10.1

TensorFlow è una framework utilizzato per il machine-learning, su di esso si basa tutta la struttura del progetto.

L'unità di base del framework è il tensore, ossia un vettore di n dimensioni, tutte le operazioni possibili vengono eseguite su elementi appartenenti a questo tipo. Inoltre contiene modelli pre-addestrati molto utili per eseguire determinate operazioni in maniera più rapida. Viene utilizzata la versione 2.10 perché è l'ultima ad avere il supporto per GPU su sistema operativo Windows.

Keras 2.10.0

Keras è un API sviluppata per rendere la codifica di IA più semplice per la comprensione umana. Minimizza le azioni richieste all'utente per i casi d'uso più comuni, rendendo l'utilizzo di framework come JAX, TensorFlow e PyTorch più user-friendly.

Scikit-Learn 1.5.2

Scikit-learn è una libreria che offre semplici tool utili per la classificazione, la regressione, il clustering, eccetera.

Matplotlib 3.9.2

Matplotlib è una libreria che viene utilizzata per la stampa dei grafici ottenuti durante le varie compilazioni.

Numpy 1.26.4

Numpy è il pacchetto che si occupa della gestione di array multi dimensionali fornendo anche un'ampia gamma di funzioni matematiche da applicare agli stessi.

OpenCV-python 4.10.0

OpenCV è una libreria utilizzata per sviluppare applicazioni di tipo computer vision. Nell'ambito del progetto il suo scopo primario è l'elaborazione delle immagini per adattarle all'utilizzo da parte delle IA.

Puppeteer 2.0.0

Puppeteer è una libreria di automazione per browser basati su chromium.

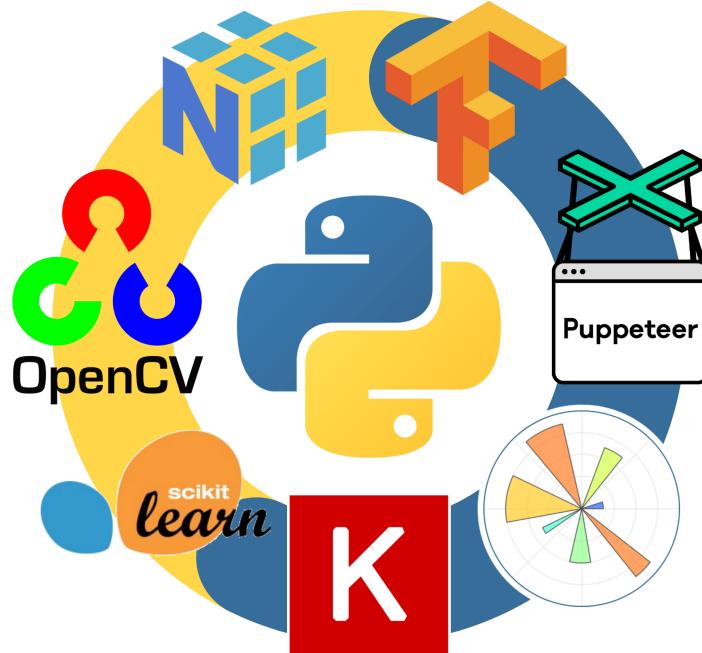


Figura 5.4: Python e librerie utilizzate

5.2.2 CUDA

Versione: 11.2

CUDA (Fig. 5.5) è un toolkit che fornisce un ambiente di sviluppo in grado di creare applicazioni che sfruttino a pieno le GPU di NVIDIA. Nel caso di studio CUDA è un elemento portante in quanto fornisce a Python e alle sue librerie la capacità di eseguire calcoli in maniera più rapida utilizzando la GPU. La GPU hanno un'architettura diversa rispetto alle CPU che consente loro di eseguire parallelamente più operazioni, per questo sono molto portate per l'addestramento delle IA. La versione 11.2 viene utilizzata perché è l'unica compatibile con [Tensorflow-gpu 2.10.1](#).



Figura 5.5: Logo di CUDA

5.2.3 Docker

Versione: 27.2.0

Docker (Fig. 5.6) è un sistema che consente di semplificare lo sviluppo delle applicazioni fornendo un ambiente isolato e facilmente riproducibile. Tale ambiente viene definito come container, al suo interno vengono eseguite le immagini di tutti i componenti necessari per il funzionamento dell'applicativo; senza che sia necessario installarli sulla propria macchina.

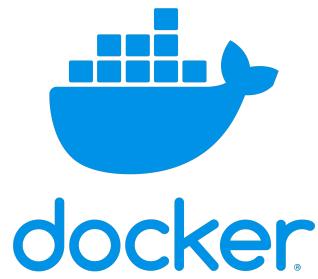


Figura 5.6: Logo di Docker

5.2.4 DDEV

Versione: 1.23.2

DDEV (Fig. 5.7) è un tool per velocizzare il lancio di ambienti di sviluppo web in locale; consente di utilizzare il workflow di Docker in maniera più rapida.



Figura 5.7: Logo di DDEV

5.2.5 WSL

Versione: 2.3.24.0

WSL (Fig. 5.8) è un sottosistema che viene utilizzato per eseguire applicazioni create per il sistema operativo Linux su Windows.



Figura 5.8: Logo di WSL

5.2.6 Laravel

Versione: 11.29.0

Laravel (Fig. 5.9) è un framework ideato per la creazione di web-application scritto in PHP. Tra i suoi vantaggi abbiamo la semplicità della sintassi, il supporto continuo della community e la presenza di numerosi tutorial che è fondamentale per fornire a sviluppatori alle prime armi l'aiuto necessario. Laravel si basa sul pattern architettonale MVC (Model View Controller):

- Model: accede ai dati contenuti nell'applicativo.
- View: mostra i dati contenuti nel model e gestisce le interazioni con gli utenti.
- Controller: riceve le operazioni degli utenti e modifica di conseguenza i dati contenuti nel model e la visualizzazione mostrata dalla view.

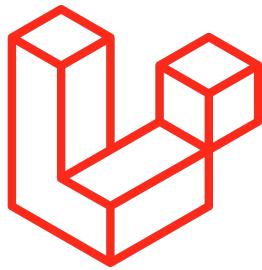


Figura 5.9: Logo di Laravel

5.2.7 Filament

Versione: 3.2.121

Filament (Fig. 5.11) è un framework basato su [Laravel](#) che fornisce la possibilità di generare componenti per l'interfaccia grafica (Fig. 5.10) in maniera rapida.

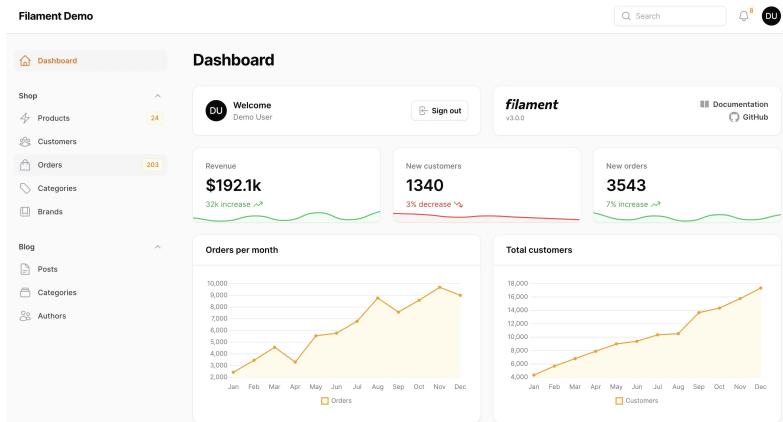


Figura 5.10: Esempio di interfaccia grafica creata in Filament



Figura 5.11: Logo di Filament

5.2.8 MySQL

Versione: 8.0.36

MySQL (Fig. 5.12) è un database relazionale open-source.



Figura 5.12: Logo di MySQL

Capitolo 6

Basi teoriche

Lorem ipsum

- 6.1 Immagini raster
- 6.2 Features
- 6.3 Autoencoder
- 6.4 PCA
- 6.5 K-means
- 6.6 Transfer learning
- 6.7 Loss functions
- 6.8 pesi
- 6.9 activation function
- 6.10 fine-tuning
- 6.11 epoche
- 6.12 learning rate

Capitolo 7

Progettazione e codifica

Durante la fase di progettazione viene definita l'architettura del software, questa operazione consiste nella suddivisione del sistema in componenti distinti, ognuno con compiti differenti. L'obiettivo è pianificare in maniera chiara tutte le azioni che l'applicativo dovrà svolgere prima di passare effettivamente alla codifica.

7.1 Architettura

L'architettura (Fig. 7.1) pensata prevede l'utilizzo di 4 componenti principali che si occupano di:

1. Acquisire gli screenshot.
2. Effettuare il clustering degli screenshot acquisiti.
3. Valutare i siti web.
4. Inviare e-mail promozionali.

La suddivisione in componenti consente di avere un codice più strutturato e specializzato nell'assolvimento di determinati compiti; rende anche la comprensione da parte di altri programmatori più rapida e chiara. I vari moduli comunicano con il database di SalesCRM attraverso l'utilizzo di API che eseguono interrogazioni e inserimenti. Nel caso della comunicazione tra il modulo di clustering e quello di valutazione la condivisione di dati avviene in maniera diretta utilizzando la memoria dello stesso PC; questa modalità non si rivela problematica poiché garantisce uno scambio rapido di informazioni che deve essere svolto solo ed esclusivamente in fase di addestramento.




Figura 7.1: Schema architetturale del progetto

7.2 Cattura immagini

La prima fase del workflow (Fig. 7.2) è composta da uno script Python che usufruisce della libreria Pypeteer per acquisire gli screenshot dei siti contenuti nel database. Più precisamente un web-scraper già implementato raccoglie i link delle pagine web dei clienti potenziali, successivamente li carica nel database di SalesCRM, dove verranno infine letti dallo script. Per funzionare Pypeteer necessita di chromium, dopo aver effettuato il controllo per verificare se esso sia presente o meno procede con la lettura dei link. L'automazione apre ogni indirizzo, aspetta qualche secondo e scatta uno screenshot. Tutte le immagini vengono poi convertite in formato Base64 e salvate nel database. La conversione in Base64 viene sfruttata perché la codifica di un'immagine in stringa consente il salvataggio diretto nelle tabelle.




Figura 7.2: Schema della fase di cattura

7.3 Clustering

7.3.1 Preparazione delle immagini

In seguito alla cattura le immagini vengono lette dal database e convertite in un formato utilizzabile dagli algoritmi di machine learning (Fig. 7.3). Per velocizzare le operazioni in fase di addestramento tutte le immagini vengono scaricate dal database e convertite in formato PNG, poiché le librerie utilizzate necessitano di dati raster per funzionare, successivamente le immagini salvate nella memoria del PC vengono processate in maniera tale da essere adatte all'utilizzo da parte di ResNet50. In questo caso le dimensioni dei tensori richieste specificatamente dal modello (Fig. 7.4) sono le seguenti (224*224*3):

- Altezza dell'immagine
- Larghezza dell'immagine
- Numero di canali (Red Green Blue)

Per rientrare nel formato richiesto le immagini subiscono un processo di scaling che ne riduce la dimensionalità lasciando il contenuto invariato. Tale operazione è stata preferita al cropping perché utilizzandolo andrebbero a perdere caratteristiche specifiche; ad esempio i margini bianchi ai lati del sito sono spesso segnale di un design un po'antiquato e migliorabile, la rimozione dei margini potrebbe compromettere il clustering impedendo la creazione di un cluster contenente pagine di quel tipo. Inoltre ogni cella contiene valori compresi tra 0 e 255, per facilitare le operazioni tali valori vengono divisi per 255 e normalizzati in un intervallo compreso tra 0 e 1.




Figura 7.3: Conversione e ridimensionamento




Figura 7.4: Struttura del tensore

7.3.2 Estrazione delle features

Per ottenere un dato utilizzabile in modo efficace dall'algoritmo di clustering è necessario modificare ulteriormente le immagini riducendole a un set di features (Fig. 7.5). Per adempire a questo compito viene utilizzato un CNN Convolutional Neural Network pre-addestrato chiamato ResNet50 (Fig. 7.6). Il modello viene caricato senza i top layers, ossia gli strati densi addetti alla classificazione, per sfruttare esclusivamente la

sua abilità di riduzione in features.




Figura 7.5: Esempio di featuremaps




Figura 7.6: Struttura di ResNet50

7.3.3 Applicazione del clustering

Le features estratte dai layers convoluzionali vengono ridotte a uno stato bidimensionale sfruttando l'analisi dei componenti principali, in questa maniera è possibile visualizzare i risultati del clustering su un grafico cartesiano, ridurre i tempi di calcolo e aumentare l'accuratezza delle predizioni; ma al costo di una ovvia perdita di informazioni. Successivamente viene applicato l'algoritmo dei K-means per l'effettiva suddivisione del dataset in clusters (Fig. 7.7). Le immagini vengono inserite, in base al cluster a loro assegnato, nelle rispettive cartelle di appartenenza. Questa operazione viene svolta per semplificare lo step successivo in cui lo sviluppatore deve preparare manualmente il dataset per l'addestramento supervisionato.




Figura 7.7: Clustering effettuato utilizzando 20 clusters e 3000 immagini

7.4 Valutazione

7.4.1 Preparazione del dataset

Il programmatore visiona i clusters ottenuti precedentemente e verifica quali possono appartenere alle categorie "siti migliorabili" e "siti ottimi"; prepara due cartelle corrispondenti alle categorie e inserisce le immagini che reputa appartenere a ciascun dominio. Lo script prepara il dataset (Fig. 7.8) secondo la logica seguente:

- Training, il 70% delle immagini viene utilizzato per l'addestramento effettivo.
- Validation, il 15% delle immagini viene utilizzato per ottimizzare i parametri del modello.
- Test, il 15% delle immagini serve per valutare l'output del modello

7.4.2 Addestramento del modello

Viene caricato il modello pre-addestrato ResNet50 escludendo i top-layers, congelando i pesi e aggiungendo degli strati personalizzati per la classificazione. Gli strati di classificazione sono successivamente addestrati utilizzando come input le features ricavate dai layers convoluzionali congelati di ResNet50.

7.4.3 Fine-tuning del modello

I layers convoluzionali vengono sbloccati e il modello viene addestrato nuovamente nella sua interezza utilizzando un learning rate ridotto in maniera tale da non modificare completamente i pesi del modello pre-addestrato. Il modello viene salvato e riutilizzato ogniqualvolta sia necessario.

7.4.4 Valutazione delle immagini

Le immagini presenti nel database vengono classificate dal modello e le valutazioni in centesimi vengono restituite.




Figura 7.8: Struttura del dataset

7.5 Invio e-mail

Le valutazioni vengono lette dal database e tramite Laravel si procede all'invio di mail personalizzate alle aziende che dispongono di siti web che potrebbero essere ancora migliorati.

7.6 Database

Il database di SalesCRM contiene molte tabelle ma in questa sezione vengono descritte solo quelle utilizzate dal workflow.

7.6.1 Domains

Questa tabella contiene tutti i siti web (Fig. 7.9) delle aziende collezionate dal web-scaper e le informazioni a essi correlati.

7.6.2 Pages

Contiene i link a tutte le pagine (Fig. 7.10) di ciascun dominio.

The screenshot shows the MySQL Workbench interface with the 'domains' table selected. The table has 13 columns:

#	Nome	Tipo	Codifica caratteri	Attributi	Null	Predefinito	Commenti	Extra	Azione
1	<u>id</u>	bigint(20)	UNSIGNED	No	Nessuno			AUTO_INCREMENT	Modifica Elimina Più
2	<u>place_id</u>	bigint(20)	UNSIGNED	Sì	NULL				Modifica Elimina Più
3	<u>url</u>	longtext	utf8mb4_unicode_ci	No	Nessuno				Modifica Elimina Più
4	<u>is_scanned</u>	tinyint(1)		No	0				Modifica Elimina Più
5	<u>is_duplicate_free</u>	tinyint(1)		Sì	0	Flag means duplicate free (pages) domain			Modifica Elimina Più
6	<u>error</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
7	<u>scan_time_ms</u>	int(11)		Sì	NULL	Time taken for a complete scan in milliseconds			Modifica Elimina Più
8	<u>rating_scan_manual</u>	int(11)		Sì	0	Rating manuale in centesimi			Modifica Elimina Più
9	<u>rating_scan</u>	int(11)		Sì	0	Rating su base AI del sito web in centesimi			Modifica Elimina Più
10	<u>num_pages_scanned</u>	bigint(20)	UNSIGNED	Sì	NULL				Modifica Elimina Più
11	<u>created_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
12	<u>updated_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
13	<u>deleted_at</u>	timestamp		Sì	NULL				Modifica Elimina Più

Below the table, there is a section for indices:

Azione	Chiave	Tipo	Unica	Compresso	Colonna	Cardinalità	Codifica caratteri	Null	Commenti
Modifica Elimina	PRIMARY	BTREE	Sì	No	id	0	A	No	
Modifica Elimina	domains_place_id_foreign	BTREE	No	No	place_id	0	A	Sì	

Figura 7.9: Schema della tabella Domains

The screenshot shows the MySQL Workbench interface with the 'pages' table selected. The table has 15 columns:

#	Nome	Tipo	Codifica caratteri	Attributi	Null	Predefinito	Commenti	Extra	Azione
1	<u>id</u>	bigint(20)	UNSIGNED	No	Nessuno			AUTO_INCREMENT	Modifica Elimina Più
2	<u>domain_id</u>	bigint(20)	UNSIGNED	No	Nessuno				Modifica Elimina Più
3	<u>url</u>	longtext	utf8mb4_unicode_ci	No	Nessuno				Modifica Elimina Più
4	<u>html_content</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
5	<u>email</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
6	<u>phone</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
7	<u>address</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
8	<u>is_checked</u>	tinyint(1)		No	0				Modifica Elimina Più
9	<u>is_downloaded</u>	tinyint(1)		No	0	Update it when downloaded image			Modifica Elimina Più
10	<u>checked_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
11	<u>check_info</u>	longtext	utf8mb4_unicode_ci	Sì	NULL				Modifica Elimina Più
12	<u>created_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
13	<u>updated_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
14	<u>deleted_at</u>	timestamp		Sì	NULL				Modifica Elimina Più
15	<u>screenshot</u>	longtext	utf8mb4_unicode_ci	Sì	NULL	Base64 image of PNG screenshot			Modifica Elimina Più

Below the table, there is a section for indices:

Azione	Chiave	Tipo	Unica	Compresso	Colonna	Cardinalità	Codifica caratteri	Null	Commenti
Modifica Elimina	PRIMARY	BTREE	Sì	No	id	0	A	No	
Modifica Elimina	pages_domain_id_foreign	BTREE	No	No	domain_id	0	A	No	

At the bottom, there is a button to create an index:

Crea un indice su 1 campi Esegui

Figura 7.10: Schema della tabella Pages

Capitolo 8

Conclusioni

- 8.1 Consuntivo finale
- 8.2 Raggiungimento degli obiettivi
- 8.3 Conoscenze acquisite
- 8.4 Valutazione personale

Appendice A

Appendice A

Citazione

Autore della citazione

Acronimi e abbreviazioni

UML Unified Modeling Language. 12, 36

Glossario

UML in ingegneria del software *UML, Unified Modeling Language* (ing. linguaggio di modellazione unificato) è un linguaggio di modellazione e specifica basato sul paradigma object-oriented. L'*UML* svolge un'importantissima funzione di “lingua franca” nella comunità della progettazione e programmazione a oggetti. Gran parte della letteratura di settore usa tale linguaggio per descrivere soluzioni analitiche e progettuali in modo sintetico e comprensibile a un vasto pubblico. [35](#)

Bibliografia

Riferimenti bibliografici

James P. Womack, Daniel T. Jones. *Lean Thinking, Second Editon*. Simon & Schuster, Inc., 2010.

Siti web consultati

Manifesto Agile. URL: <http://agilemanifesto.org/iso/it/>.